

AI生成学术文献 虚假率分析报告

基于三学科（管理学、经济学、社会学）
两模型（豆包、DeepSeek）的对比分析

学科	豆包（错误/总数）	DeepSeek（错误/总数）
管理学	48/50（96.0%）	46/50（92.0%）
经济学	34/50（68.0%）	35/50（70.0%）
社会学	6/66（9.1%）	43/48（89.6%）
综合	88/166（53.0%）	124/148（83.8%）

报告日期：2026年06月11日

数据来源：手动校准文献列表 × AI模型生成文献列表

一、研究概述

随着大语言模型（LLM）在学术研究中的广泛应用，AI生成文献引用的准确性问题日益凸显。为系统评估主流大模型在学术文献生成任务中的虚假文献率，本项目选取三个学科领域（管理学、经济学、社会学）的CSSCI核心期刊论文作为测试集，对比分析豆包和DeepSeek两个模型的表现。

测试方法：为每个学科提供约50篇真实论文的检索条件，要求模型生成标准参考文献格式。将模型输出与人工校准版本逐条比对，标记所有实质性差异（排除空格、标点符号等不影响文献检索的微小格式差异）。

1.1 数据规模

学科	豆包条目	DeepSeek条目	校准条目
管理学	50	50	50（标注为基准）
经济学	50	50	50（标注为基准）
社会学	66	48	105（独立校准）
合计	166	148	—

注：管理学和经济学的校准判断嵌入在Word文件的人工标注中；社会学拥有独立的校准列表和结构化差异报告（V4版）。

1.2 虚假文献判定标准

实质性差异定义为以下任一类型的错误（排除空格、标点符号等不影响文献检索的微小格式差异）：


- 题目不存在/编造 —— 论文标题在对应期刊中完全不存在（最严重）
- 期刊名错误 —— 论文被错误归属到其他期刊
- 卷/期错误 —— 卷号或期号编造
- 页码错误 —— 起止页码与实际不符
- 年份/时间错误 —— 发表年份与实际不符
- 作者错误 —— 姓名、顺序错误或张冠李戴
- DOI错误/缺失
- 标题差异 —— 标题存在实质性文字差异（如副标题缺失）
- 字段不完整 —— 元数据字段缺失

二、虚假文献率总体统计


学科	豆包错误	总数	虚假率	DS错误	DS总数	DS虚假率
管理学	48	50	96.0%	46	50	92.0%
经济学	34	50	68.0%	35	50	70.0%
社会学	6	66	9.1%	43	48	89.6%
综合	88	166	53.0%	124	148	83.8%

* 社会学V4报告：实质性差异62条（差异明细表共77行，涉及49个唯一条目 + 1条模型独有）。
其中 DeepSeek 43/48（89.6%），豆包 6/66（9.1%）。

2.1 虚假文献率对比



2.2 热力图总览



三、错误类型分布分析


3.1 严重虚假：题目完全编造

定义：模型生成的论文标题在真实期刊中完全不存在。这是最严重的虚假类型，意味着模型凭空捏造了一篇看似合理的学术论文。这类文献如果被实际引用，将导致引用链完全断裂。

3.2 部分虚假：字段级差异


定义：论文真实存在，但模型在元数据（期刊名、卷期、页码、作者、年份等）上出现了错误。通过题目、作者等信息仍可检索到原文，影响引用准确性但不阻断检索。

3.3 错误类型分布图



说明：社会学豆包6条差异均为“标题差异”（标点/引号格式），属最轻微级别。DeepSeek社会学以卷/期错误（34处）和标题差异（35处）为主。

3.4 严重程度对比



3.5 各学科错误详情

管理学

模型	错误类型	条数
豆包	题目不存在/编造	46
豆包	字段不完整；题目不存在/编造	2
DeepSeek	题目不存在/编造	46

经济学

模型	错误类型	条数
豆包	题目不存在/编造	11
豆包	年份/时间错误；期刊名错误	7
豆包	页码错误	6
豆包	期刊名错误；页码错误	3
豆包	卷/期错误；期刊名错误	2
豆包	期刊名错误	1
豆包	作者错误；年份/时间错误；期刊名错误	1
豆包	作者错误；页码错误	1
豆包	卷/期错误；年份/时间错误；期刊名错误	1
豆包	作者错误	1
DeepSeek	页码错误	33
DeepSeek	卷/期错误；页码错误	2

社会学

模型	错误类型	条数
豆包	标题差异	6
DeepSeek	卷/期错误	34
DeepSeek	标题差异	9

注：经济学错误类型常为复合类型，上表计数涉及全部类别，各计数之和可能超过错误总条数。
社会学差异明细中，DeepSeek的卷/期错误34处 + 标题差异35处来自43个唯一条目（部分条目同时有卷和标题差异）。

四、虚假文献常见特征总结

4.1 题目完全编造（管理学重灾区）

发生率：豆包管理学46/50篇题目不存在（92%），DeepSeek管理学46/50篇题目不存在（92%）。经济学豆包有11篇题目不存在。社会学无论豆包还是DeepSeek均无题目编造——差异集中在元数据字段。

典型模式一（拼凑式编造）：模型将常见学术关键词组合成语法正确、主题合理、但在期刊中实际不存在的标题。如“组织支持感对员工工作绩效的影响机制研究”、“协同创新、知识转移与企业创新绩效”——这些标题看起来完全像真实的CSSCI论文。

典型模式二（期刊错配式编造）：将某期刊常见主题论文编造为另一期刊的文章，如将创新管理主题编造为《管理世界》论文，将组织行为学主题编造为《南开管理评论》论文。

4.2 期刊名错误（经济学突出）

经济学豆包多篇论文被错误归属到其他期刊。如将发表在《经济学（季刊）》的论文归属到《经济研究》，将《中国工业经济》论文归属到《管理世界》。模型对不同CSSCI期刊的边界认识模糊。

4.3 页码捏造（DeepSeek经济学标志性错误）

DeepSeek经济学35条错误中33条涉及页码。模型生成的页码格式规范（如1-10、45-68），但起始页码与实际不符。页码数字往往很“整齐”，与真实论文的页码分布规律不符。

4.4 社会学领域的两极分化

豆包（9.1%虚假率）：仅6条差异，全部为标点/引号格式差异（如冒号「:」与中文冒号「：」的差异），严格来说不属于“虚假文献”。

DeepSeek（89.6%虚假率）：43/48条有差异，以卷/期错误（34处）和标题差异（35处）为主。卷/期错误主要表现为模型生成的文献缺少卷号标注（如2025年论文缺“第40卷”）。标题差异主要是标点符号格式不一致。

4.5 学科差异总结

管理学：两个模型均极差（>90%），以题目编造为主。管理学论文命名规律不明显、期刊论文量巨大，模型难以准确记忆具体论文。

经济学：错误类型多样化，DeepSeek以页码错误为主（较轻微），豆包以题目编造和期刊错误为主（较严重）。

社会学：两个模型极端分化——豆包近乎完美（9.1%），DeepSeek系统性出错（89.6%）。表明模型能力存在但训练数据覆盖面不均衡。

五、结论与建议

5.1 核心发现

1. 综合虚假率：豆包 53.0%（88/166），DeepSeek 83.8%（124/148）。不同学科和模型间存在巨大的表现差异（从9.1%到96.0%）。
2. 管理学是重灾区：两个模型在该学科的虚假率均超过90%，且绝大部分为题目完全编造——属于最严重的虚假类型。AI生成的管理学文献引用基本不可用。
3. 社会学豆包例外：在社会学领域虚假率仅9.1%，所有差异均为标点格式差异，说明模型在特定领域的训练数据覆盖可以显著降低虚假率。
4. DeepSeek模式特征：以字段级错误为主（卷/期、页码），而非题目编造。经济学中35条错误有33条是页码问题；社会学中43条错误以卷/期缺失和标题标点差异为主。

5.2 使用建议

对研究人员：AI生成的文献引用不能直接使用，必须逐条验证。建议以AI生成为起点，通过DOI或学术数据库（知网、Web of Science）逐条核实。管理学领域的AI生成文献尤其不可信。

对模型开发者：建议增加文献真实性约束机制（如强制附带DOI验证、与学术数据库实时比对），或为学术写作等高风险场景提供“仅检索不生成”模式。

对赛题设计：本报告可作为“AI生成文献可信度评估”赛道的基线数据，建议后续扩大覆盖学科范围和模型种类。

本报告由自动分析脚本生成，数据来源为比赛文件夹中的人工校准标注和模型输出对比。

报告生成时间：2026-06-11 23:44:30